

## 1. GIỚI THIỆU

### 1.1. Định nghĩa vấn đề:

- Input:** dựa vào tập train lựa chọn các đặc trưng để huấn luyện mô hình.
- Output:** Dự đoán khả năng sống sót ở tập test.

### 1.2. Thử thách:

- Dữ liệu có vài đặc trưng thiếu giá trị
- Một số đặc trưng có kiểu dữ liệu không đúng
- Mô hình cần cân bằng giữa độ chính xác và khả năng tổng quát, tránh overfitting


**1.3. Mục tiêu báo cáo:** Xây dựng và đánh giá mô hình dự đoán khả năng sống sót của hành khách trên tàu Titanic dựa trên các đặc trưng cá nhân và thông tin về tàu.

## 2. DATASET:

- Bộ dữ liệu gồm 2 tập (train, test):
  - Tập train gồm có 891 mẫu và 12 đặc trưng
  - Tập test gồm có 418 mẫu và 12 đặc trưng
- Data source:

<https://colab.research.google.com/drive/1Y P29RvhKPuBYc4vUO87fD4JLkQFc2ImK>

## 3. PHƯƠNG PHÁP ĐỀ XUẤT



### 3.1. Data summarization:


```

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 891 entries, 0 to 890
Data columns (total 12 columns):
#   Column      Non-Null Count  Dtype
---  -
0   PassengerId  891 non-null    int64
1   Survived     891 non-null    int64
2   Pclass       891 non-null    int64
3   Name         891 non-null    object
4   Sex          891 non-null    object
5   Age          714 non-null    float64
6   SibSp        891 non-null    int64
7   Parch        891 non-null    int64
8   Ticket       891 non-null    object
9   Fare         891 non-null    float64
10  Cabin        204 non-null    object
11  Embarked     889 non-null    object
dtypes: float64(2), int64(5), object(5)
memory usage: 83.7+ KB
None
    
```

Thông tin về bộ dữ liệu tập Train

### 3.2. EDA

#### 3.2.1. Giá trị thiếu



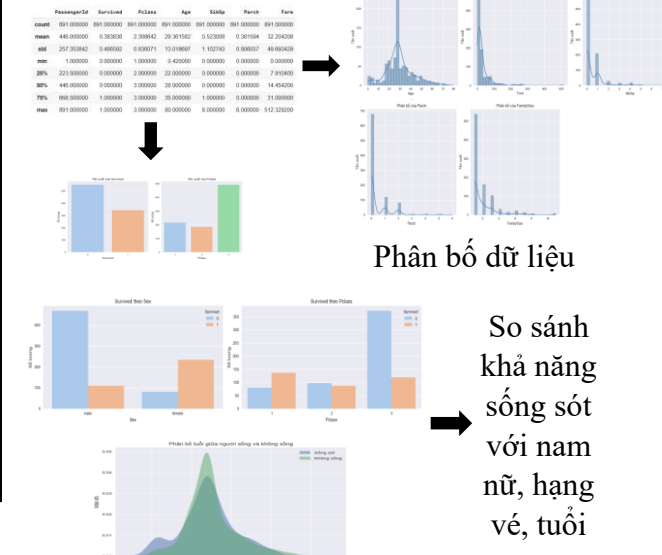
Xử lý giá trị thiếu

```

train_df.isnull().sum()
train_df.isna().sum()

PassengerId    0
Survived        0
Pclass          0
Name            0
Sex             0
Age             0
SibSp           0
Parch           0
Ticket          0
Fare            0
dtype: int64
    
```


#### 3.2.2. Thống kê mô tả



Phân bố dữ liệu

So sánh khả năng sống sót với nam nữ, hạng vé, tuổi

### 3.3. Feature selection



Chọn đặc trưng

Age, 'Fare', 'FamilySize', 'Sex', 'Pclass\_2', 'Pclass\_3']

## 4. Model training, evaluation

```

from sklearn.model_selection import train_test_split
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=0)

from sklearn.linear_model import LogisticRegression
model = LogisticRegression()
model.fit(X_train, y_train)

from sklearn.metrics import accuracy_score, confusion_matrix, classification_report
y_pred = model.predict(X_test)

print("Accuracy: ", accuracy_score(y_test, y_pred))
print("Confusion Matrix: ", confusion_matrix(y_test, y_pred))
print("Classification Report: ", classification_report(y_test, y_pred))
    
```

```

Accuracy: 0.810858659217877
Confusion Matrix:
[[89 16]
 [18 56]]
Classification Report:
precision    recall  f1-score   support

0           0.83     0.85     0.84     105
1           0.78     0.76     0.77     74

accuracy: 0.81
macro avg: 0.80     0.80     0.80     179
weighted avg: 0.81     0.81     0.81     179
    
```

81% mẫu validation được dự đoán đúng. Hàng đầu tiên = class 0 (không sống sót). True Negative = 89 (dự đoán đúng là 0). False Positive = 16 (dự đoán sống sót nhầm). Hàng thứ hai = class 1 (sống sót). False Negative = 18 (dự đoán không sống sót nhầm). True Positive = 56 (dự đoán đúng là sống sót). Precision (1) = 0.78 số dự đoán sống sót. Recall (1) = 0.76 số người thật sự sống sót. F1-score (1) = 0.77 → kết hợp precision & recall. Class 0 có hiệu suất nhỉnh hơn → phù hợp với mắt cân bằng nhân (số người không sống sót > số người sống sót).

## 5. Prediction

PassengerId	Survived	Sex	Age	SibSp	Parch	Ticket	Fare	Embarked	Pclass_2	Pclass_3	FamilySize
0	0	Male	29.69	0	0	330911	7.25	C	False	True	1
1	0	Male	35.00	1	0	330912	7.25	C	False	True	2
2	0	Male	35.00	1	0	330913	7.25	C	False	True	1
3	0	Male	35.00	1	0	330914	7.25	C	False	True	1
4	0	Male	35.00	1	0	330915	7.25	C	False	True	1

Output

Passenger	Survived
892	0
893	0
894	1
895	1
896	1
897	0
898	1
899	0
900	0
901	0